

Изометрическое вложение и функциональная регрессия

Автор: Быков Владимир, ИСУ 465327

Дисциплина: Функциональный анализ

Материалы: кейс3.ipynb, кейс4.ipynb, functional_rto_case4_submit.py

Аннотация

В работе рассмотрены два прикладных сюжета, связанных с анализом объектов, заданных не стандартным набором признаков. В кейсе 3 изучается восстановление евклидовой конфигурации точек по матрице попарных расстояний. В кейсе 4 рассматривается регрессия по функциональным данным: входной объект является функцией или временным профилем, а признаки строятся с помощью линейных функционалов.

Для кейса 3 реализованы проверка метрических свойств, двойное центрирование, спектральное восстановление координат, анализ ошибок, исследование влияния размерности и шума. Для кейса 4 реализованы интегральные функционалы, сравнение базисов, МНК, ridge-регрессия, восстановление функции весов, эксперименты на гладких и кусочно-гладких функциях, а также применение идеи функциональной регрессии к реальным данным РТО магазинов.

Ключевые слова

Матрица расстояний, матрица Грама, двойное центрирование, изометрическое вложение, MDS, функциональные данные, линейный функционал, функциональная регрессия, ridge-регрессия, РТО.

Воспроизводимость

Основные вычисления выполнены в ноутбуках:

- кейс3.ipynb - изометрическое вложение и матрица расстояний;
- кейс4.ipynb - функциональная регрессия;
- functional_rto_case4_submit.py - воспроизводимое решение для реальных данных РТО и формирование test.csv.

Интерактивные графики сохранены в папках:

- figures_case3/;
- figures_case4/.

Кейс 3. Изометрия и матрица расстояний

Постановка задачи

Пусть дано конечное множество объектов

$$X = \{x_1, \dots, x_n\}$$

и матрица попарных расстояний

$$D = (d_{ij})_{i,j=1}^n, d_{ij} = d(x_i, x_j).$$

Требуется понять, можно ли найти точки

$$y_1, \dots, y_n \text{ в } \mathbb{R}^m$$

такие, что

$$\|y_i - y_j\| = d_{ij}$$

для всех i, j . Если точное вложение невозможно, нужно построить приближение и оценить ошибку.

Данные

В работе использованы четыре типа данных:

1. Синтетические точные данные: $n = 32$ точки в $\mathbb{R}^3$, сгенерированные из нормального распределения.
2. Точки на окружности: отдельный пример точного двумерного вложения.
3. Шумные данные: к точной матрице расстояний добавлялся симметричный шум с нулевой диагональю.
4. Реальные данные: крупнейшие города России из `worldcitiespop.csv`, для которых известны широта, долгота и население.

Для реального эксперимента были выбраны 40 городов России с наибольшим населением. Географические координаты были переведены в локальную плоскую километровую проекцию, после чего по ним была построена матрица евклидовых расстояний.

Проверка метрических свойств

Для матрицы расстояний проверялись:

- нулевая диагональ;
- симметричность;
- неотрицательность;
- неравенство треугольника.

Проверка неравенства треугольника выполнялась прямым перебором троек индексов (i, j, k) . Для каждой тройки проверялось условие

$$D_{ik} \leq D_{ij} + D_{jk}.$$

Для $n = 32$ было проверено $32^3 = 32768$ троек. В шумных экспериментах дополнительно считалась доля троек, для которых это неравенство нарушается.

Для синтетических точных данных получено:

Проверка	Значение
Максимальная ошибка диагонали	0.0
Максимальная ошибка симметрии	0.0
Минимальное значение в D	0.0
Проверено троек	32768
Нарушений треугольника	0
Доля нарушений	0.0

Число 32768 возникает не как размер матрицы, а как количество троек индексов:

$$32^3 = 32768.$$

Сама матрица расстояний имеет размер 32 x 32.

Двойное центрирование

Если точки y_i уже заданы, их матрица Грама равна

$$B = (b_{ij}), b_{ij} = \langle y_i, y_j \rangle.$$

Матрица Грама симметрична. Действительно, ее элементы задаются скалярными произведениями:

$$b_{ij} = \langle y_i, y_j \rangle.$$

В вещественном евклидовом пространстве скалярное произведение симметрично:

$$\langle y_i, y_j \rangle = \langle y_j, y_i \rangle.$$

Следовательно,

$$b_{ij} = b_{ji},$$

то есть

$$B = B^T.$$

Расстояния выражаются через скалярные произведения:

$$d_{ij}^2 = \|y_i - y_j\|^2 = b_{ii} + b_{jj} - 2b_{ij}.$$

Обозначим матрицу квадратов расстояний через

$$D^{(2)} = (d_{ij}^2).$$

Для восстановления матрицы Грама нужно устранить произвольный перенос конфигурации. Поэтому будем считать, что точки центрированы:

$$\sum_{i=1}^n y_i = 0.$$

Тогда для матрицы Грама центрированной конфигурации выполняется

$$B1=0, 1^T B=0.$$

Из равенства

$$d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}$$

выразим b_{ij} . Усредним это равенство по индексу j . Так как строки B суммируются в ноль, получаем

$$\text{mean}\{d_{i.}^2\} = b_{ii} + (1)/(n) \sum_{j=1}^n b_{jj}.$$

Аналогично при усреднении по i :

$$\text{mean}\{d_{.j}^2\} = b_{jj} + (1)/(n) \sum_{i=1}^n b_{ii}.$$

Если усреднить по двум индексам сразу, то

$$\text{mean}\{d_{..}^2\} = (2)/(n) \sum_{i=1}^n b_{ii}.$$

Подставляя эти выражения в исходную формулу расстояний, получаем поэлементную формулу двойного центрирования:

$$b_{ij} = -1/2(d_{ij}^2 - \text{mean}\{d_{i.}^2\} - \text{mean}\{d_{.j}^2\} + \text{mean}\{d_{..}^2\}).$$

То есть из матрицы квадратов расстояний нужно вычесть средние по строкам и столбцам и добавить общее среднее.

Введем матрицу центрирования

$$J = I - (1)/(n) \mathbf{1}\mathbf{1}^T.$$

Тогда матрица Грама центрированной конфигурации восстанавливается по формуле

$$B = -1/2 J D^{(2)} J,$$

где $D^{(2)}$ - матрица квадратов расстояний.

Действительно, умножение на J слева вычитает средние по столбцам, а умножение на J справа вычитает средние по строкам. Поэтому элемент матрицы $J D^{(2)} J$ равен

$$d_{ij}^2 - \text{mean}\{d_{i.}^2\} - \text{mean}\{d_{.j}^2\} + \text{mean}\{d_{..}^2\}.$$

Отсюда получается матричная формула

$$B = -1/2 J D^{(2)} J.$$

Центрирование необходимо, потому что расстояния не меняются при переносе всей конфигурации. Если заменить все точки на $y_i + a$, то расстояния $\|y_i - y_j\|$ сохранятся, но матрица Грама изменится, так как скалярные произведения зависят от выбора начала координат. Умножение на J выбирает единственного представителя с нулевым средним:

$$y_i^{\text{centered}} = y_i - 1/n \sum_{k=1}^n y_k.$$

Именно поэтому двойное центрирование устраняет неопределенность, связанную с переносом всей конфигурации.

В вычислениях получено:

Величина	Значение
$\max_abs(B - B^T)$	0.0
$\max_abs(J1)$	0.0
$\max_abs(B1)$	8.88e-15

Последнее значение имеет порядок машинной точности.

Спектральное восстановление

Матрица B симметрична, поэтому для поиска собственных значений использовался метод `np.linalg.eigh`. Он предназначен для вещественных симметричных матриц и возвращает вещественный спектр с ортонормированными собственными векторами.

Спектральное разложение:

$$B = U \Lambda U^T.$$

Координаты восстанавливаются по положительным собственным значениям:

$$Y = U_r \Lambda_r^{1/2}.$$

Тогда

$$YY^T = U_r \Lambda_r U_r^T = B_r.$$

Для синтетического примера:

Показатель	Значение
Порог tol	2.966e-09
Положительных собственных значений	3
Нулевых собственных значений	29
Отрицательных собственных значений	0
Ранг B	3

Первые собственные значения:

29.66003209, 18.79241177, 7.19447121, 0, 0, ...

Ранг B равен минимальной размерности точного евклидова вложения. В данном случае исходные точки были в R^3 , и восстановленный ранг также равен 3.

Связь ранга и минимальной размерности следует из представления $B = YY^T$. Для центрированной конфигурации

$$\text{rank}(B) = \text{rank}(YY^T) = \text{rank}(Y).$$

Ранг матрицы Y равен размерности линейной оболочки центрированных точек. Поэтому именно число положительных собственных значений матрицы Грама задает минимальную размерность пространства, в котором возможно точное вложение.

Ошибки восстановления

Восстановленная матрица расстояний сравнивалась с исходной по метрикам:

$$E_{\max} = \max_{\{i,j\}} |d_{\{ij\}} - d_{\text{hat}_{\{ij\}}}|,$$

$$E_F = ||D - D_{\text{hat}}||_F,$$

$$E_{\text{rel}} = (||D - D_{\text{hat}}||_F) / (||D||_F).$$

Вложение	E_max	E_F	E_rel
Полная положительная размерность	2.66e-15	2.84e-14	4.75e-16
2D	1.4903	8.4371	0.1414
3D	2.66e-15	2.84e-14	4.75e-16

Полное 3D-восстановление совпадает с исходной геометрией с точностью до численной ошибки. 2D-вложение является приближением: оно визуально сохраняет общую структуру, но дает ненулевую ошибку расстояний.

Ошибка Прокруста для сравнения восстановленных 3D-координат с исходными:

9.23e-16

Это подтверждает восстановление исходной конфигурации с точностью до движения пространства: сдвига, поворота и отражения.

Такое выравнивание необходимо, потому что координаты, восстановленные по одной только матрице расстояний, не определены единственным образом. Если всю конфигурацию сдвинуть, повернуть или отразить, все попарные расстояния сохраняются. Поэтому прямое сравнение координат без выравнивания некорректно; в работе использовалось прокрустово выравнивание, после которого сравнивались исходные и восстановленные координаты.

Зависимость от размерности

Размерность m	E_F	E_rel
1	25.3389	0.4246
2	8.4371	0.1414
3	2.84e-14	4.75e-16

При уменьшении размерности часть спектра отбрасывается, поэтому ошибка восстановления расстояний возрастает. Если спектр быстро убывает, низкоразмерное вложение может быть хорошим приближением.

Устойчивость к шуму

К точной матрице расстояний добавлялся шум:

$$D^{\{\epsilon\}} = D + \epsilon R,$$

где R - симметричная матрица с нулевой диагональю.

epsilon	Отрицательных собственных значений	E_rel	Доля нарушений треугольника
0.00	0	4.75e-16	0.0000

epsilon	Отрицательных собственных значений	E_rel	Доля нарушений треугольника
0.01	14	0.0037	0.0018
0.03	14	0.0112	0.0051
0.05	14	0.0187	0.0086
0.10	14	0.0375	0.0152
0.15	14	0.0565	0.0202
0.20	14	0.0757	0.0275
0.30	14	0.1141	0.0403

Шум приводит к появлению отрицательных собственных значений у матрицы Грама. Это означает, что шумная матрица расстояний уже не является точной евклидовой матрицей расстояний.

Интерпретация этого эффекта следующая. Для точной евклидовой матрицы расстояний после двойного центрирования должна получаться положительно полуопределенная матрица Грама. Добавление произвольного симметричного шума нарушает согласованность расстояний с некоторой евклидовой конфигурацией. Поэтому матрица перестает быть положительно полуопределенной, а в спектре появляются отрицательные собственные значения.

Реальные данные: города России

Для проверки метода на реальных данных был использован датасет `worldcitiespop.csv`. Из него были выбраны 40 крупнейших городов России с известным населением и координатами. Для каждого города были взяты широта и долгота, затем координаты были переведены в локальную плоскую проекцию:

$$x = R \cos(\lambda), y = R \sin(\phi),$$

где $R = 6371$ км - радиус Земли, ϕ - широта, λ - долгота, $\bar{\phi}$ - средняя широта выбранных городов.

После этого была построена матрица евклидовых расстояний между городами и применен тот же алгоритм двойного центрирования и спектрального восстановления.

Показатель	Значение
Число городов	40
Положительных собственных значений	2
Отрицательных собственных значений	0
E_max	1.09e-11
E_F	8.56e-11
E_rel	8.67e-16
Корреляция расстояний	1.0000
Ошибка Прокруста	2.14e-12 км

Полученный ранг 2 ожидаем: координаты городов были представлены в двумерной плоской проекции. Восстановление по матрице расстояний совпало с исходной картой с точностью до движения плоскости.

Визуализация

Ниже приведены статические версии ключевых интерактивных графиков Plotly из ноутбука.




Рис. 1. Спектр матрицы Грама: три положительных собственных значения соответствуют размерности исходного пространства.




Рис. 2. Двумерное вложение сохраняет основную структуру, но не является точным изометрическим восстановлением.




Рис. 3. Проекция восстановленного 3D-вложения; в полной размерности ошибка восстановления имеет порядок машинной точности.




Рис. 4. Ошибка уменьшается при росте размерности и практически исчезает при $m = 3$.




Рис. 5. При росте шума увеличиваются относительная ошибка и доля нарушений неравенства треугольника.




Рис. 6. Сравнение исходных и восстановленных расстояний в 2D; точки близки к диагонали, но видна ошибка усечения.




Рис. 7. Реальные координаты 40 крупнейших городов России в плоской километровой проекции.




Рис. 8. Восстановление карты городов России по матрице расстояний методом двойного центрирования.




Рис. 9. Исходные и восстановленные расстояния между городами совпадают с точностью до численной ошибки.

Основные графики:

- [figures_case3/eigenvalues.html](#) - спектр матрицы B;
- [figures_case3/embedding_2d.html](#) - двумерное вложение;
- [figures_case3/embedding_3d.html](#) - трехмерное вложение;
- [figures_case3/error_by_dimension.html](#) - ошибка от размерности;
- [figures_case3/noise_errors.html](#) - устойчивость к шуму;
- [figures_case3/distance_scatter.html](#) - исходные и восстановленные расстояния;
- [figures_case3/circle_embedding.html](#) - пример с окружностью.
- [figures_case3/worldcities_real.html](#) - исходная карта городов России;
- [figures_case3/worldcities_mds.html](#) - восстановление городов по расстояниям;
- [figures_case3/worldcities_spectrum.html](#) - спектр матрицы Грама для городов;
- [figures_case3/worldcities_distances.html](#) - сравнение исходных и восстановленных расстояний между городами.

Для 2D-вложения корреляция между исходными и восстановленными расстояниями:

$$\text{corr}(D, D_{\text{hat}_{2D}}) = 0.9627$$

Это показывает, что 2D-визуализация сохраняет значительную часть структуры, но не является точным изометрическим вложением.

Именно здесь проявляется различие между визуально удачным и количественно точным восстановлением. 2D-вложение выглядит информативно и имеет высокую корреляцию расстояний, но относительная ошибка равна $E_{\text{rel}} = 0.1414$. Поэтому оно подходит для визуализации, но не является точным изометрическим восстановлением. В 3D-вложении ошибка имеет порядок 10^{-16} , поэтому оно является количественно точным для синтетических данных.

Выводы по кейсу 3

1. Двойное центрирование позволяет восстановить матрицу Грама центрированной конфигурации по матрице расстояний.
2. Положительная полуопределенность B является критерием евклидовой реализуемости расстояний.
3. Число положительных собственных значений равно минимальной размерности точного вложения.
4. Для точных синтетических данных восстановление в R^3 является практически точным.
5. При переходе к 2D появляется ошибка, но корреляция расстояний остается высокой.
6. Шум нарушает евклидову структуру и приводит к отрицательным собственным значениям.
7. На реальных данных городов России алгоритм восстановил двумерную карту по матрице расстояний с ошибкой порядка машинной точности.

Кейс 4. Регрессия по функциональным данным

Постановка задачи

В кейсе 4 объект наблюдения задается функцией

$$x(t), t \in [a, b].$$

Требуется предсказать числовой ответ y . Для перехода от функции к конечному набору признаков используются линейные функционалы:

$$L_{\{\phi\}}(x) = \int_a^b x(t)\phi(t) dt.$$

Если выбрана система функций $\phi_1, \dots, \phi_m$, то для каждого объекта строятся признаки

$$z_{ik} = \int_a^b x_i(t)\phi_k(t) dt.$$

После этого задача сводится к линейной регрессии:

$$\hat{y}_i = \beta_0 + \sum_{k=1}^m \beta_k z_{ik}.$$

Данные

В кейсе 4 использованы три типа данных:

1. Синтетические гладкие функции:

$$x_i(t) = a_i \sin(2t) + b_i \cos(2t) + c_i t + \epsilon_i(t).$$

2. Кусочно-гладкие функции:

$$x_i(t) = \alpha_{i1} \{[0, 0.3]\}(t) + \beta_{i1} \{[0.3, 0.7]\}(t) + \gamma_{i1} \{[0.7, 1]\}(t) + \epsilon_i(t).$$

3. Реальные данные РТО магазинов из файла `train_2.csv`. История РТО магазина рассматривалась как функция времени, заданная на месячной сетке.

Численное интегрирование

Функции заданы на равномерной сетке:

$$t_1, \dots, t_q \in [0, 1].$$

Интегралы приближались методом трапеций:

$$\int_a^b x(t)\phi(t) dt \sim \sum_{j=1}^q w_j x(t_j)\phi(t_j).$$

Для гладкого синтетического эксперимента:

Показатель	Значение
Число функций	220
Число точек сетки	201
Интервал	$[0, 1]$

Системы функционалов

Рассмотрены две системы:

1. Интервальные функционалы - средние значения функции на подотрезках.
2. Тригонометрический базис - функции $1, \sin, \cos$ с нормировкой.

Для тригонометрического базиса проверялась ортонормированность. Матрица скалярных произведений для первых пяти функций:

```
[[ 1.  0. -0.  0. -0.]  
 [ 0.  1.  0.  0.  0.]  
 [-0.  0.  1. -0. -0.]  
 [ 0.  0.  0.  1.  0.]  
 [-0.  0. -0.  0.  1.]]
```

Также проверялась линейность функционалов:

$$L_{\{\phi\}}(\alpha x + \beta z) = \alpha L_{\{\phi\}}(x) + \beta L_{\{\phi\}}(z).$$

Максимальная численная ошибка линейности:

8.33e-17

Метод наименьших квадратов

После построения матрицы признаков Z вводится расширенная матрица дизайна X , содержащая столбец единиц. Модель:

$$\hat{y} = X\beta.$$

Функционал МНК:

$$Q(\beta) = (y - X\beta)^T (y - X\beta).$$

Нормальные уравнения:

$$X^T X = X^T y.$$

При обратимости $X^T X$:

$$= (X^T X)^{-1} X^T y.$$

На практике использовалось численно устойчивое решение через `np.linalg.lstsq` или `ridge-регрессию`.

Функция весов

Модель можно переписать в функциональной форме:

$$\hat{y}(x) = \beta_0 + \sum_{k=1}^m \beta_k \langle x, \phi_k \rangle.$$

Если

$$w(t) = \sum_{k=1}^m \beta_k \phi_k(t),$$

то

$$\hat{y}(x) = \beta_0 + \langle x, w \rangle.$$

Функция $w(t)$ показывает, какие участки функции сильнее влияют на прогноз.

Результаты на гладких синтетических функциях

Система функционалов	Выборка	MSE	RMSE	R2
Интервалы	train	0.00608	0.07801	0.99610
Интервалы	test	0.00639	0.07993	0.99664
Тригонометрия	train	0.00600	0.07744	0.99616
Тригонометрия	test	0.00605	0.07780	0.99682

Тригонометрический базис дает немного лучшее качество, что соответствует способу генерации данных: функции содержат синусоидальные компоненты.

Для ridge-регрессии лучший параметр:

$\lambda = 0.01616$

Лучшее тестовое значение:

$RMSE = 0.07867$

На графике зависимости RMSE от λ видно, что при больших значениях λ ошибка растет. Это связано с тем, что регуляризация становится слишком сильной: коэффициенты модели сжимаются к нулю, функция весов $w(t)$ чрезмерно сглаживается, и модель начинает недообучаться. В этом эксперименте выбранные функционалы уже хорошо описывают данные, поэтому сильная регуляризация не требуется; оптимальное значение λ оказалось малым.

Результаты на кусочно-гладких функциях

Кусочно-гладкие функции были добавлены как второй синтетический сценарий. В этом случае интервальные функционалы особенно естественны, потому что данные сами состоят из постоянных участков.

Система функционалов	Выборка	MSE	RMSE	R2
Интервалы	train	0.00578	0.07602	0.96900
Интервалы	test	0.00603	0.07764	0.97025
Тригонометрия	train	0.00574	0.07578	0.96920
Тригонометрия	test	0.00597	0.07725	0.97055

Обе системы дают близкое качество. Интервальные функционалы лучше интерпретируются в этом эксперименте: они прямо отвечают за средние уровни на участках $[0, 0.3]$, $[0.3, 0.7]$, $[0.7, 1]$.

Реальные данные РТО

Дополнительно идея кейса 4 применялась к реальным данным РТО магазинов. Файл `train_2.csv` содержит:

- 18657 магазинов;
- историю с января 2023 по февраль 2025;

- 26 месяцев наблюдений;
- числовые и категориальные признаки магазинов;
- целевую переменную РТО.

История РТО магазина рассматривалась как функция времени. По окну из 12 месяцев строились функциональные признаки:

- проекции на базис $1, t, t^2, \sin, \cos$;
- интервальные средние;
- трендовые характеристики;
- сезонные признаки.

Решалась задача прогноза РТО на следующий месяц. Для формирования сабмита на март 2025 был создан файл `test.csv`.

Валидация проводилась на последнем известном переходе: январь 2025 -> февраль 2025.

Модель	MAPE на валидации
Функциональная ridge-модель	9.1431%
Остаточная функциональная ridge-модель	9.1431%
Сезонный переход прошлого года	7.5258%

Финальный файл `test.csv` был выбран по лучшей валидации. На платформе организаторов он получил:

87.45 баллов

Скрипт воспроизведения:

`functional_rto_case4_submit.py`

Сабмиты:

- `test.csv` - основной файл;
- `test_functional_ratio.csv` - функциональная модель отношения;
- `test_functional_residual.csv` - функциональная модель остатка.

Графики кейса 4

Интерактивные графики из ноутбука представлены ниже в статическом виде.

Примеры функциональных наблюдений




Рис. 10. Примеры гладких функциональных наблюдений, используемых в синтетическом эксперименте.

Восстановленная функция весов




Рис. 11. Восстановленная функция весов $w(t)$: тригонометрический базис лучше соответствует гладкой синусоидальной структуре данных.




Рис. 12. Зависимость RMSE от числа функционалов: качество меняется при увеличении размерности функционального представления.




Рис. 13. Ridge-регрессия: при больших lambda модель недообучается, поэтому RMSE растёт.




Рис. 14. Кусочно-гладкий случай: интервальные функционалы дают хорошо интерпретируемую функцию весов.




Рис. 15. Реальные данные РТО: сравнение MAPE на валидационном переходе январь 2025 -> февраль 2025.

Основные графики:

- [figures_case4/sample_functions.html](#) - примеры гладких функциональных наблюдений;
- [figures_case4/basis_trig.html](#) - тригонометрический базис;
- [figures_case4/basis_gram.html](#) - проверка ортонормированности;
- [figures_case4/prediction_scatter.html](#) - прогнозы и истинные ответы;

- [figures_case4/weight_functions.html](#) - восстановленная функция весов;
- [figures_case4/rmse_by_m.html](#) - качество от числа функционалов;
- [figures_case4/ridge_lambda.html](#) - зависимость ridge от lambda;
- [figures_case4/noise_grid.html](#) - устойчивость к шуму и сетке;
- [figures_case4/piecewise_functions.html](#) - кусочно-гладкие функции;
- [figures_case4/piecewise_weights.html](#) - веса в кусочно-гладком случае;
- [figures_case4/rto_validation.html](#) - результаты на РТО.

Выводы по кейсу 4

1. Линейные функционалы позволяют переводить функции в конечномерные признаки.
2. Выбор системы функционалов должен соответствовать структуре данных: для синусоидальных данных естественен тригонометрический базис, для кусочно-гладких - интервальные признаки.
3. Функция весов $w(t)$ делает модель интерпретируемой: она показывает вклад участков функции в прогноз.
4. Ridge-регрессия стабилизирует коэффициенты и полезна при большом числе функционалов.
5. На реальных данных РТО функциональный подход дал воспроизводимую модель, но простой сезонный переход оказался сильнее на выбранной валидации.

Общие выводы

Кейс 3 и кейс 4 показывают два способа работы с нетипичными входными данными.

В кейсе 3 исходными данными является не координатное описание объектов, а матрица расстояний. Через двойное центрирование и спектральное разложение удастся восстановить координаты и понять минимальную размерность вложения.

В кейсе 4 исходными данными является функция или временной профиль. Через линейные функционалы функция превращается в вектор признаков, после чего можно применять линейную регрессию и ridge-регрессию. При этом модель остается интерпретируемой через функцию весов.

Оба кейса используют одну общую идею: сложный объект заменяется конечномерным представлением, но это представление строится не произвольно, а с учетом геометрии или функциональной структуры задачи.